个人简历

基本信息

姓名：黄泊凯
性别：男
联系电话：13600323338
邮箱：3347620766@qq.com
个人技术主页：github.com/ILVACM | gitee.com/ILVACM\

本简历为完整版母版，既是唯一事实来源，也是个人经历的完整展示；欢迎各位面试官查阅指正。
注：本简历为非投递件，正式投递请使用按目标公司定制的实例版本。

求职意向： AI应用开发工程师 / 后端研发工程师 / 软件研发工程师（AI+系统集成方向）

教育&专业背景

广东工业大学 | 计算机学院 | 软件工程（本科，2027届毕业） | 2023.09 - 至今

- **算法基础：** 大一上入选 校 ACM 算法集训队（19名入队）。
- **专业拓展：** 大一下加入 校“华为-昇腾”创享社工作室（嵌入式方向），关注硬件集成应用。
- **产研经历：** 大一下加入 广工 广东省物理信息融合实验室国家地方工程中心，师从 黄国恒 副教授。

关键经历汇总

时间	经历/项目	角色	要点
2023	广东工业大学“华为杯”程序设计赛	—	三等奖 · 校 ACM 集训队
2024.10 - 2025.01	南方电网广州电力工程监理有限公司 · 办公自动化 RPA 辅助软件开发项目	技术负责人	JSON 配置化引擎 · 报表自动化 · 数据模板解耦
2024.09 - 2026.09	机场物流集团 · 智慧物流系统迭代一期/二期	项目总负责人（二期）	全生命周期 · 11 类违规行为算法 · 类脑芯片适配
2025.09 - 2026.09	广东交科检测有限公司 · 钢筋直径与间距检测设备原型研发	技术负责人	双节点边缘架构 · UNet 分割推理 · 多传感器融合
2024.06 - 2024.10	南网数字研究院/江门供电局 · 边缘布控球自适应目标检测与视频调控系统	技术总负责人	端云协同架构 · 云台自适应跟踪 · 图像质量评估
2025.06 - 至今	广东省自然科学基金2026课题研究 · 模态缺失下的轻量化诊疗报告生成研究	核心算法开发成员	基金申请书 · 多模态数据流水线 · RAG 闭环验证
2025.03 - 2025.06	广州光点信息科技股份有限公司 · 全媒体热点追踪与 AI 自动化短视频生成矩阵系统	Python 开发实习生（AI 研发组）	反爬采集 · 双 STT 引擎 · 大模型微服务化
2025.07 - 2025.10	广东省国土资源测绘院 · GDCORS智能知识库与政企本地化RAG问答系统	卫星应用中心 系统开发实习生	微内核架构 · 数据隔离分流 · 检索增强

时间	经历/项目	角色	要点
2026.08 - 至今	多 Agent 协作的工程规约体系	独立设计者与实现者	三层逻辑 · 锚点双向绑定 · harness 化演进

重要经历

·· 校企横向项目经历

南方电网广州电力工程监理有限公司 | 办公自动化 RPA 辅助软件开发项目 | 2024.10 - 2025.01

项目名称：面向电力工程监理业务的数据清洗与报表自动化 RPA 系统（已验收交付）

相关技术栈：Python, Pandas, Openpyxl, Win32COM, PyInstaller, JSON 配置化引擎, GUI

项目背景：南方电网广州电力工程监理有限公司的监理业务存在明确的信息化需求——"次日基建计划统计、C/D 类违章代码核查、周计划出勤核算"等日报/周报填报高度重复，需人工跨系统导出数据并在 Excel 中完成多条件嵌套统计，流程冗长且易错。

价值规模：￥10 万

承担角色：技术负责人

个人工作总述：作为技术负责人，主责该系统的核心设计与实现——业务 SOP 抽象、JSON 配置化映射引擎、GUI 交互封装与工程化交付打包均由本人独立完成，是该项目技术方案的主要提出者与落地者。

核心工作与工程产出：

- **复杂业务逻辑的抽象与数据清洗流水线构建**：
  - 深入调研甲方业务SOP，将高度定制化的 Excel 筛选、分列、多条件嵌套统计需求，抽象为一套高复用的 Pandas 数据处理函数库。
  - 攻克异构数据源融合难题，实现 XLS/XLSX 格式的底层 COM 组件自动转换、空白行列智能剔除、以及基于正则与分隔符（如 `\` 层级路径）的供电局单位精准提取，保障了多源数据合并（Merge）的准确性。
- **架构升级决策：从「硬编码写表」到「数据-模板解耦」**：
  - 摒弃传统的硬编码写表方式，将统计结果（按督查形式、建设单位、违章代码等多维交叉统计）先输出为结构化 JSON，再由 `config.json` 中的坐标映射规则驱动，自动注入目标 Excel（如《第三方督查计划管控表》）的指定单元格。
  - 该决策把"报表结构"从代码中剥离为配置：甲方报表模板变更时**只需修改配置文件而无需改动核心代码**，使系统的可维护性与生命周期不再受模板变动牵制。
- **零代码可视化交互引擎（面向非技术用户）**：
  - 将数据表勾选、督查人员反匹配过滤、统计口径选择等操作全部收敛到可视化界面与配置文件，使甲方业务人员在**不接触任何代码**的前提下自助完成从数据导入到报表输出的全流程。
  - 搭建配套的桌面级工程化交付链路（全局日志捕获、PyInstaller 打包与资源路径适配），确保软件在甲方无 Python 环境的 Windows 内网终端上稳定运行；交付后新增报表或调整口径均由配置完成，无需研发介入。
- **业务价值**：系统成功交付并应用于广州电力工程监理有限公司日常安全督查与计划管控业务。将原本每天需耗时 1.5 小时的手工导出与统计填报工作**缩减至 3 分钟内完成**，彻底消除了人工统计导致的错漏，获

得甲方业务部门的高度评价。

机场物流集团 | 智慧物流系统迭代一期/二期 | 2024.09 - 2026.09

项目名称：机场物流智慧物流系统迭代校企合作框架协议项目（一期交付 / 二期验收）

相关技术栈：Python, C++, YOLOv5s, DeepSORT, ST-GCN, 灵汐HS100-L(KA类脑芯片), LynSDK, Docker, MySQL

项目背景：机场物流集团在海关物流安检与转运库区管理两类场景中存在明确的智能化需求——一期需降低海关人工查验强度、提升安检效率；一期验收后甲方高层进一步提出将 AI 辅助工作流横向拓展至物流转运库区的违规行为监控。

价值规模：￥90 万（一期 35 万 / 二期 55 万）

承担角色：项目总负责人（二期）

个人工作总述：一期参与项目、二期升任项目总负责人——独立统筹二期从业务调研、技术合同拟定到架构设计、验收交付的全生命周期，并主导 11 类违规行为算法开发与国产类脑芯片算力适配，是本项目由一期延续至二期的核心技术负责人。

核心工作与工程产出：

- **全生命周期项目统筹与商业交付（二期总负责人）：**
  - 作为二期项目（55万）总负责人，**独立主导项目全生命周期管理**。从前期业务调研、合作意向洽谈、技术合同拟定，到关键节点立项、系统架构设计及最终验收交付，均作为核心决策者推进，保障项目按期高质量交付。
- **多场景AI视觉算法攻坚与国产化边缘算力部署（二期核心技术）：**
  - 主导库区11类典型违规行为（如车辆超速、人员离岗、晕倒摔倒等）的算法开发。基于 DeepSORT 构建运动轨迹分析模块，结合 MediaPipe 与 ST-GCN 时空图卷积网络进行时序行为分析，初期模型检出准确率达 60%-70%（目标提升至80%+）。
  - **攻克国产边缘算力适配难题**：将模型成功部署至 **北京灵汐 HS100-L 边缘计算盒子**（搭载 KA系列类脑芯片，提供 32 TOPS INT8 算力）。使用 **Model Tool** 完成 ONNX 模型到灵汐专有格式的转换与算子适配；基于 **LynSDK (C/C++)** 重构推理管线，结合 ARM Cortex-A53 主控进行端到端内存与线程优化，满足单路视频延迟 ≤200ms、实时处理 ≥25FPS 的严苛指标。
- **IoT硬件底座与现场部署（一期核心沉淀）：**
  - 深入海关业务一线，独立完成安检机硬件组装、机械组件调试及电气设备负载校验（确保供电功率与线路负载达标），保障底层数据采集的物理稳定性。
  - 在甲方技术总经理指导下，深度践行企业级高可用系统设计规范，完成专用机房服务器集群的部署与IoT架构落地。
- **云边协同监控体系与DevOps闭环（一期核心沉淀）：**
  - 设计基于 Docker 容器化的 B/S 架构部署方案。在边缘侧引入 **LynSMI** 实时监控 APU 算力水位与设备温度，并结合 **Prometheus+Grafana** 构建全方位云边监控体系（定义CPU/内存/应用等15+告警规则）。
  - 开发 Shell 自动化部署脚本与 MySQL 定时备份方案，建立故障诊断流程，使 P1 故障恢复时间 <5 分钟，系统整体可用性达 99.5%。
- **多端协同与场景化分层架构设计：**
  - 针对库区违规场景分别设计分层技术架构（如车辆超速场景的「感知 → 时空建模 → 轨迹决策 → 响应中枢 → 系统赋能」五层），明确各层职责边界与层间契约。

    - 落地为「边缘端智能终端承担轻量化推理 + 中央服务器承担归档、检索与深度分析」的多端协同形态，兼顾现场实时性与集中治理能力。
- **系统平台架构设计与演进：**
    - 平台侧架构由**传统 Spring Boot 分层**起步，随后按业务 SOP 重组为**纵向业务分层**，最终收敛为以**通信中枢为中心的星形（Hub-Spoke）拓扑**：各组件不再两两直连，统一经中枢的协议网关 / 通道定义 / 路由中枢对接，把"组件间两两耦合"收敛为"组件对中枢的单一契约"，新增组件或替换协议均不影响既有链路，并按 **100TB 视频数据归档**与**亿级事件记录快速检索**的设计要求规划存储与检索结构。
    - 配套**二维数据分类治理**（业务语义 × 数据形式）明确各类数据的通道与存储归属；边缘设备以**五态机**（installing / ready / fault / maintain / removed）管理，覆盖注册、就绪、故障、维护到移除的全生命周期。

广东交科检测有限公司 | 钢筋直径与间距检测设备原型研发 | 2025.09 - 2026.09

项目名称：钢筋直径与间距检测设备原型（POC 原型技术验证交付）

相关技术栈：Python, PyTorch, UNet(ResNet50), OpenCV/NumPy, gRPC + Protobuf, Orbbec Gemini 336L 深度相机, STP23L 激光测距(S21C 主控), tkinter, Jetson Nano(Ubuntu/CUDA) + OrangePi KunPeng(openEuler), JSON 配置化, Docker

项目背景：广东交科检测有限公司在工程质量检测环节存在明确的自动化需求——施工现场钢筋直径与间距长期依赖人工卡尺抽检，效率低且易漏检。同时现场要求本地闭环运行、不依赖外网与云端。

价值规模：￥25 万

承担角色：技术负责人

个人工作总述：作为技术负责人，独立完成设备的双节点边缘系统架构、双节点通信协议、AI 推理管线与多传感器融合换算方案的总体设计，并主导全部代码实现与端到端联调，是该项目技术方案的设计者与第一实现者。

核心工作与工程产出：

- **双节点边缘系统架构设计：**
    - **架构决策与权衡：**针对推理与采集 / 渲染 / 串口在单板上争抢资源、导致掉帧与 UI 卡顿的问题，将 AI 推理负载与系统调度负载**物理隔离为两个节点**——检测节点（Jetson Nano，Ubuntu 22.04 + CUDA）专职 UNet 推理，服务节点（OrangePi KunPeng，openEuler）负责相机采集、激光解析、测量换算与人机交互。以节点间通信成本为代价，换取三重收益：资源不再争抢、**故障域相互隔离**、推理节点可**独立换型升级**。
    - 设计双向 gRPC 通信协议（自定义 protobuf）：服务节点 → 检测节点的 `Infer` 推理 RPC（JPEG 图像进、PNG 类别掩码出），检测节点 → 服务节点的 `Heartbeat` / `Shutdown` RPC，双方向各自独立 channel，避免双向调用复用同一连接。
- **项目级 Agent 规约体系与架构规范前置：**
    - 在仓库根建立 `AGENTS.md` 作为项目最高权威架构文档与**面向 Agent 的约束层**，冻结模块划分、通信协议与开发规范；节点设计文档（检测节点 / 服务节点）以「上层架构规范见 `AGENTS.md` 」分层承接，各自只写专属实现细节，形成「约束层 → 实例层」两级文档体系。
    - 该约束使 AI Agent 能按规约参与模块开发，同时保证多节点设计不越界、协议不漂移。
- **AI 推理管线与检测节点实现：**

    - 构建 UNet（ResNet50 backbone）3 类语义分割推理管线：等比缩放 + 灰边填充装入 640×640 输入框（画面不变形）→ ImageNet 均值方差标准化 → GPU 前向 → 裁除灰边并插值回原图尺寸 → 逐像素 argmax，输出 0=背景 / 1=纵向钢筋 / 2=横向钢筋 的单通道掩码。
    - 实现节点状态机（IDLE → INFERENCING → RETURNING）、启动自检与 systemd 服务化部署脚本，支撑现场无人值守运行。
- **多传感器融合与测量换算**：
    - 打通“4 路 STP23L 激光探头 → S21C 主控汇总 → Type-C 串口 → 服务节点”数据链路，实现 11 字节串口帧解析与热插拔自动扫描重连（含 USB 节点路径漂移自适应）；设计零值/负值/超量程剔除与全无效兜底的数据有效性检查。
    - 实现 4 路激光融合策略（均值 / 中位数 / 指定路 / 手动输入），运行期可动态切换；基于“mm/px = 工作距离 ÷ 相机内参 fx”完成像素到物理尺寸换算，输出直径并就近对齐 6~40mm 国标规格系列，同时按连通域与扫描线计算相邻钢筋间距。
- **可靠性设计与工程规范**：
    - 设计帧同步机制（frame_id 主键 + 毫秒时间戳辅助校验），严格保证 RGB 原图、距离标量、类别掩码三者一一对应；乱序、迟到或标识不符的帧直接丢弃，杜绝跨帧错配。
    - 实现节点健康监测与自动降级：5 秒周期心跳 + 连续 3 次丢失（15 秒）判定离线 + best-effort 退出通知 + 响应状态捎带；推理节点不可用时系统自动降级为“仅视频 + 激光”模式，不影响现场查看。
    - 全量值类参数 JSON 配置化（严禁硬编码）、双节点统一日志格式（一机一日志，10MB×5 轮转）与归档规范，保障跨节点联调时两条时间线可对齐。
    - 上述帧同步、心跳降级、配置化与日志规范共同构成该双节点系统的**协议冻结 — 状态机 — 自动降级**治理闭环，使其在无人值守现场可自证状态、可安全退化。
- **当前进展**：已完成双节点代码资产拆分与实现，端到端原型已交付（POC 技术验证完成）。

·· 学术纵向课题经历

南网数字研究院/江门供电局 | 边缘布控球自适应目标检测与视频调控系统 | 2024.06 - 2024.10

项目名称：边缘布控球自适应目标检测与视频调控系统

项目性质：实验室-南网数字研究院/江门供电局企业合作课题（已完成）/ 后续立项为广东省省级大创项目（本人任技术总负责人）

硬件平台：广州英码 IPV09A 边缘盒子 (海思 Hi3519DV500 NPU)

项目背景：南网数字研究院/江门供电局在电网施工布控球的视频监控环节存在明确的技术需求——布控球部署于弱网、边缘算力受限（无 GPU/CUDA）的作业现场，视频质量与目标跟踪效果难以保障。该课题先行以企业合作课题形式立项并完成，后续立项为广东省省级大创项目。

承担角色：技术总负责人

个人工作总述：以大创技术总负责人身份主导端云协同架构设计与《图像质量评估及优化方案》主笔，独立完成云台自适应跟踪算法（YOLOv8 + ByteTrack + Lerp 平滑控制）的验证与数据集评估，是该课题核心方案的主导设计者与算法验证者。

核心工作与科研产出：

- **端云协同架构设计与方案统筹**：

    - 主导系统架构设计，主笔撰写《图像质量评估及优化方案》。针对海思平台算力瓶颈，设计了“边缘端客观指标（Brenner/平均亮度）初筛 + HSV 明度自适应调整”与“服务端基于 Transformer 的 NR-IQA 拟人化评估 + 多任务驱动深度修复”的折中架构，有效平衡了边缘端算力与评估精度。
- **边缘端云台自适应跟踪算法验证：**
    - 独立编写基于 YOLOv8 与 ByteTrack 的视频跟踪测试脚本。设计并实现了基于线性插值（Lerp）与帧间平滑算法的云台控制逻辑，通过计算检测框边界与中心点偏移量，输出平滑的 x/y 轴偏移与焦距缩放（Zoom）控制信号，为布控球硬件云台的自适应跟踪提供了可靠的算法验证基线。
- **评估体系构建与数据集测试：**
    - 协助构建电网场景多曝光图像融合数据集（WireFO-MEF）。制定图像亮度与清晰度的主观打分标注规范，编写自动化测试脚本验证评估体系，确保边缘端客观评分召回率/精准率达 70% 以上，服务端主客观一致评分达 80% 以上，为后续核心算法的迭代提供了量化评估支撑。

广东省自然科学基金2026课题研究 | 模态缺失下的轻量化诊疗报告生成研究 | 2025.06 - 至今

项目名称：模态缺失下的轻量化诊疗报告生成研究（项目编号：2026A1515010964，负责人：黄国恒副教授）

项目性质：广东省自然科学基金 2026 年面上项目（省级科研课题）

相关技术栈：多智能体系统 (Multi-Agent), RAG, 医学大模型微调 (SFT), Linux/Docker

项目背景：本课题由导师提出并立项——广东省自然科学基金 2026 年面上项目《模态缺失下的轻量化诊疗报告生成研究》（编号 2026A1515010964），针对临床诊疗报告生成中"多模态数据缺失可解释性差、大模型生成易产生医学幻觉、多时序模型参数冗余"三大瓶颈，研究"补全-验证-轻量化"技术链；依托中山大学肿瘤防治中心 600+ 例胸腺瘤/鼻咽癌多模态私有数据集，旨在为临床提供精准、高效、低幻觉的智能诊疗报告生成系统。本人在课题立项后参与，承担算法实现与工程化相关工作。

承担角色：核心算法开发成员

个人工作总述：作为核心算法开发成员，承担课题组从科研筹备到工程落地的关键工作——协助导师完成基金申请书核心章节撰写，独立负责 GPU 训练环境搭建与 600+ 例多模态数据标准化流水线，并完成多模态特征编码、多时序轻量化模型的基础代码实现与 Multi-Agent + RAG 架构的工程验证。

核心工作与科研产出：

- **科研前期筹备与基金申请书撰写：**
    - 深度参与项目前期的文献调研，系统性阅读并整理了数十篇多模态医学影像、大模型幻觉抑制及轻量化网络相关的顶会/顶刊文献。
    - 汇总对比了多种 Baseline 技术路线（如跨模态补全策略、多智能体协同框架），协助导师与团队完成了《广东省自然科学基金面上项目申请书》中核心研究内容、技术路线图及研究方案部分的撰写与打磨。
- **算法工程实现与 RAG 架构验证：**
    - 负责将团队设计的理论算法转化为可运行的 PyTorch 代码。以复现和模仿顶刊论文及行业开源示范案例为主，完成了多模态特征编码模块、多时序轻量化模型的基础代码搭建与接口封装。
    - 参与多智能体（Multi-Agent）系统的工程架构设计与验证，实现了智能体间的串行与并行调度逻辑；通过接入 RAG（检索增强生成）外挂临床指南知识库，协助验证了“诊断-验证-仲裁”闭环机制在抑制医学幻觉方面的工程可行性。
- **实验环境构建与数据标准化流水线：**

    - 独立负责实验室 GPU 服务器的环境配置与依赖管理（基于 Docker/Conda），确保多节点分布式训练环境的高度一致性。
    - 针对中山大学肿瘤防治中心的 600+ 例多模态私有数据集，编写自动化脚本进行数据清洗、脱敏、ROI 裁剪与对齐，制定了严格的输入输出数据标准化规范，保障了后续模型训练的数据质量与实验的可重复性。
- **核心算法协助与实验结果分析：**
    - 在课题最高难度的理论创新部分（如四元数卷积算子设计、SVD 低秩分解算法重构），以跟随博士生师兄学习为主，深入理解其数学推导与物理意义。
    - 协助师兄开展核心算法的测试验证与结果校对工作，编写脚本对模型训练过程中的 Loss 曲线、注意力权重及特征分布进行数据参数可视化，为算法的持续调优提供直观的数据支撑。

·· 企业实习经历

广州光点信息科技股份有限公司 | Python 开发实习生（AI 研发组） | 2025.03 - 2025.06

项目名称：全媒体热点追踪与 AI 自动化短视频生成矩阵系统

相关技术栈：Python, FastAPI, Playwright, faster-whisper, SenseVoice, vLLM, Celery, Docker

项目背景：公司 MCN 业务存在明确的效率痛点——热点追踪依赖人工、短视频产出周期长，难以支撑矩阵号的规模化运营；公司为此立项研发全链路自动化系统，实现从多平台热点捕获、音视频解析、大模型文案二创到下游数字人合成的业务闭环。本人以实习生身份加入该项目。

个人工作总述：作为 AI 研发组实习生，独立负责反爬采集链路、本地双 STT 引擎部署与智能路由、大模型微服务化封装与云边混合推理调度等核心模块，是该项目"监控-生成-合成"全链路的主要工程实现者之一。

核心工作与工程产出：

- **基于 UI 自动化的反爬虫数据采集与清洗：**
    - 针对短视频平台严苛的反爬机制，放弃脆弱的协议逆向，采用 `Playwright` 编写模拟真人交互的自动化采集脚本（注入随机延迟、鼠标轨迹与动态视口渲染）。实现层级遍历逻辑，自动解析热榜并抓取无水印视频，结合 `Pandas` 构建数据清洗流水线，保障核心业务数据的稳定输入。
- **本地化 STT 引擎部署与混合路由调度（核心难点）：**
    - 兼顾数据隐私与调用成本，在本地算力服务器独立部署 `faster-whisper (large-v3)` 与阿里 `SenseVoice` 双语音识别引擎。
    - 设计智能路由策略：利用 `FFmpeg` 提取音频并经 `Silero VAD` 切片；短切片及中文口语优先路由至 `SenseVoice` 保障时效，长音频及嘈杂环境路由至 `Whisper` 保障准确率，在有限算力下实现精度与速度的最优解。
- **大模型能力的服务化剥离与混合推理调度（架构解耦）：**
    - **能力剥离：**将大模型能力从主业务流剥离，基于 FastAPI 封装为独立微服务，提供"长文案要点提取"与"短视频脚本二创"标准 RESTful 接口，使业务迭代与模型迭代互不阻塞。
    - **路由权衡：**本地节点以 vLLM 部署 Qwen2.5-14B 与 Llama 3 承载常规信息提取（成本与数据可控），复杂创意任务动态路由至云端商业大模型 API（质量优先）——本质是**成本 / 时延 / 质量**的三角权衡。
    - **韧性设计：**API Key 池轮询 + 指数退避重试，把外部限流的不确定性收敛在调度层内部。
- **异步编排与跨系统协作契约：**
    - 引入 `Celery + Redis` 构建异步任务队列，解耦耗时的视频下载与模型推理流程；与下游"数字人合成系统"以标准化 JSON 数据交换协议交接脚本、时间轴与素材元数据，把跨部门对接成本固化

为一次性的接口约定。

- **业务价值**：系统成功打通“监控-生成-合成”全链路，将单条热点追踪到视频产出的全流程耗时从人工数小时压缩至 15 分钟内，为公司矩阵号的自动化运营提供了高可用技术底座。

广东省国土资源测绘院 | 卫星应用中心 系统开发实习生 | 2025.07 - 2025.10

项目名称：GDCORS智能知识库与政企本地化RAG问答系统

相关技术栈：Spring Boot 3.x + DIFY/LangChain（逻辑中枢）, RAGFLOW + Milvus（存储与检索）, Qwen3 API + vLLM（本地/远程混合推理）, BERT 微调（意图识别）, MinerU + OCR/STT（多模态解析）, React/Vue + TypeScript（多端 UI）, Docker

项目背景：单位存在明确的知识管理需求——院内积累大量非结构化专业文档（GDCORS 操作手册、测绘规范、扫描版图纸）与 PB 级地理空间业务数据，技术人员定位故障与查询规范依赖人工翻阅；同时受政企数据"不出域"的合规约束，无法直接使用公有大模型服务。该项目以**实习三方协议**形式立项，本人以系统开发实习生身份承担本地化 RAG 系统的开发。

个人工作总述：作为系统开发实习生，采用「逻辑核心 + 功能插件」微内核架构完成系统总体设计，并主导该 RAG 系统从 0 到 1 的技术实现——需求期望管理、PB 级文档解析与向量化流水线、意图路由与多路召回检索增强、LLM-as-a-Judge 量化评估体系及本地化部署均由本人主责推进。

核心工作与工程产出：

- **需求调研、期望管理与跨部门协同推进：**
  - 深入业务一线与测绘专家及院领导进行多轮需求调研，有效管理甲方对大模型“无所不能”的过高期望。通过展示早期Demo与量化评估数据（边界测试Case），成功说服甲方将项目核心目标从“开放式通用问答”收敛至“基于专业规范的精准检索与故障排查”，规避了项目范围蔓延（Scope Creep）。同时，在数据“绝对不出域”的严苛合规要求下，与院信息中心沟通博弈，争取到本地算力服务器资源，并协调业务部门完成首批核心数据的盘点与授权，保障项目顺利推进。
- **微内核架构与六层分层设计：**
  - 采用「**逻辑核心 + 功能插件**」的微内核架构：逻辑核心层承担业务调度与插件管理、支持插件热加载与动态增删，插件支持层以标准接口挂载向量库、模型服务与意图识别等能力，使检索链路各环节可独立替换而不触动核心。
  - 配套六层分层（基础硬件平台层 → 数据采集与处理层 → 逻辑核心层 → 插件支持层 → 服务集成层 → 应用交互层），在满足"数据不出域"的前提下兼顾可扩展性与解析精度。
- **PB 级多源数据治理与向量化流水线：**
  - 覆盖「采集 → 清洗 → 结构化 → 向量化」全流程：由 ETL 工具链与多模态解析引擎接入多源异构资料（含扫描版图纸与复杂表格），经去噪、去重与格式统一后按业务维度分类、标签化与索引化，再经向量化写入 Milvus 向量库。
  - 针对海量导入设计「分片并行 — 异步向量化 — 分布式索引」流水线，以异步任务队列承载耗时处理，实现千万级文档块的高效存储与检索。
- **数据隔离分流与权限治理：**
  - 以本地部署的 BERT 微调模型承担**用户意图二分类路由**：判定查询指向内部资料还是外部信息——内部分支直接走本地知识库检索响应（数据不出内网），外部资料经安全通道受控访问，从机制上实现数据隔离分流。
  - 配套细粒度权限控制（普通员工 / 项目经理 / 管理员三级）与防泄密机制，按角色限定数据访问与使用范围。
- **复杂意图路由与多路召回检索增强：**

    - 针对测绘领域长尾且复杂的查询需求，设计“意图识别路由”模块，精准分发问答、文档检索或系统操作指令。引入 HyDE（假设性文档嵌入）、多路召回（向量+BM25）及 BGE-Reranker 上下文重排序机制，大幅提升专业领域检索的准确率与召回率。
- **LLM-as-a-Judge 评估体系与闭环迭代：**
    - 从0到1构建 RAG 系统量化评估体系，设计基于“LLM-as-a-Judge”的自动化打分脚本，从相关性、准确性、幻觉率三个维度对生成结果进行量化评测。基于评估数据反哺 Prompt 模板优化与 Chunking 策略调整，使系统专业问答忠实度 ≥95% / 相关率 ≥90%。
- **本地化大模型部署与 DevOps 交付：**
    - 基于 vLLM 框架在本地算力服务器上量化部署开源大模型（如 Qwen3），结合 Docker 与 Nginx 实现微服务的容器化打包与反向代理，保障系统在内网弱网环境下的稳定运行与高并发响应。

·· 个人工程实践

多 Agent 协作的工程规约体系 | 独立设计与迭代 | 2026.08 - 至今

项目名称：面向多 Agent 协作的工程规约体系（提示词工程 → harness 的中间态）

项目性质：个人工程实践（自主立项，无外部委托）

相关技术栈：本地 Agent 工具（TRAE / WorkBuddy）、提示词工程、Markdown 规约体系、Mermaid、Git 版本治理

项目背景：在使用本地 Agent 承担真实工程任务的过程中发现——直接向 agent 下达任务不可靠，其产出依赖**无歧义的引导**与**从弱到强的约束规范**，而这一特征恰好与软件工程的实践规范同构。据此以提示词工程为起点，设计并持续迭代出一套可移植的工程规约体系：人负责需求分析、方案设计、技术选型与验收标准，由规约约束 agent 行为并交付符合预期的结果。

承担角色：独立设计者与实现者

个人工作总述：独立完成体系的架构设计、机制设计与演进路线规划，产出 4 份设计文档（体系设计稿 / 27 项机制清单 / Git 提交追踪机制分析 / harness 化演进方案），并已在个人仓库中落地运行其核心条款。

核心工作与设计产出：

- **体系架构设计（三层逻辑 + 双载体）：**
    - 将体系划分为约束层 / 知识层 / 实例层三层逻辑，约束力逐级递减、禁止实例层反向依赖，并配套豁免机制与文档生命周期状态机（draft / active / deprecated / archived / exempt）。
    - 落地为两处载体：根目录 `AGENTS.md` 作约束层唯一载体与体系总入口，`.spec/` 承载知识层与索引；给出九类必含章节与九条终态判据，使任意 Agent 进入仓库后仅凭体系内文件即可重建上下文。
- **机制设计（把可追溯性落成机制，而非口头要求）：**
    - **任务执行锚点机制：**规定层 / 锚点层 / 详情层三层追踪，锚点层只存「5 秒可读」摘要、详情外链到每任务一个记录文件；配套「读 → 比 → 确认」续接校验，重启时不采信记录而先与实物交叉验证。
    - **Git 提交追踪机制：**以任务锚点给提交「打桩」，实现**锚点 ↔ commit hash 双向绑定**；规定路径限定提交（禁止 `git add -A` 裹挟在途变更）、提交消息强制模板、破坏性命令红线（`reset --hard` / `push --force` / `filter-branch` 等），并新增 `GV-01~05` 校验条款。
- **工程判断与风险处置：**

    - 主动校正方案中的三处前提偏差——「同账户只读 = 安全边界」（实为防误操作护栏）、「SQLite 可防内容幻觉」（只保证结构与引用一致、不保证内容正确）、「数据库二进制入库」（破坏 diff → 改为可重建派生物）。
    - 坚持保留**降级模式**：无脚本环境下体系仍须可用，脚本是增强项而非前置依赖。
- **harness 化演进规划**：
    - 规划体系由「全提示词」向代码化过渡：L0 条款 / L1 契约 / L2 实现 / L3 状态 / L4 证据五层分离；按「机器可判定 / 机器可辅助 / 纯意图」三分法界定下沉边界；规划 `validate / check / anchor / render / hash` 五类 CLI 并**先行冻结接口契约**；以真实缺陷沉淀 golden cases 评测集。

竞赛与荣誉

- **2024年**
    - **华为2024昇腾AI创新大赛**：最具商业潜力奖（高校赛道）
    - **华为2024鲲鹏应用创新大赛**：全国半决赛（开发板赛道）
    - **第17届中国大学生计算机设计大赛**：3项作品入围省赛（担任团队负责人）
    - **南方电网视觉识别内部竞赛（拉线锈蚀赛道）**：第8名（担任团队负责人）
- **2023年**
    - **广东工业大学“华为杯”程序设计赛**：三等奖（以校内第19名成绩入选校 ACM 集训队）
    - **PTA 天梯团体算法竞赛**：全国高校第五名（作为校 ACM 集训队核心成员参赛）
    - **2023“合泰”杯单片机应用设计竞赛**：省级二等奖
    - **马蹄杯（百度之星）程序设计大赛**：省级三等奖